TrustGTR

项目完整计划与实验路线

TrustGTR: Reliability-Aware Multi-Cycle Global Retrieval for Time Series Forecasting

面向时间序列预测的可靠性感知多周期全局检索网络

> **从官方复现出发，用可复核的实验回答：当前样本应该参考哪段历史，以及这些历史模式值得信任多少？**

项目项	本文档口径
文档版本	v1.0 · 2026-10-05
证据截止	第五轮正式实验结束；全部数值从持久化 metrics 自动读取
当前阶段	官方复现完成；创新仍处于单 seed 快速筛选
已选数据	ETTh1、Solar；输入 96、预测 96，seed 2024
研究范围	A 多周期历史记忆、B 可靠性门控、C 状态对比检索，完整保留
项目位置	/mnt/data/zza/code/TrustGTR

当前最重要的判断

ETTh1 的 A5 为 **0.366727 / 0.391116**，相对原 GTR 的 MSE / MAE 降低 **0.7770% / 0.3792%**。完整 ABC5 也改善两项指标，但弱于 A5。新版历史检索尚未在 Solar 正式验证；独立模块贡献和统计稳定性仍待建立。

本文档同时给出已完成事实、研究假设、后续实验和停止扩张条件。工作标题保留原设想；“独立长周期建模”尚不能作为已验证结论。

01 阅读导航与范围

页码	内容	用途
1	项目封面与证据快照	快速理解当前状态
2	阅读导航与范围	区分事实与计划
3	研究问题与 A/B/C 贡献	确认完整创新范围
4	官方复现协议	公平比较的固定条件
5	A：历史记忆与检索	当前实现及周期定义
6	B：可靠性门控	回退与收益监督
7	C：状态对比检索	正负样本与训练边界
8	版本演进与负结果	保留失败原因与修正
9	最新正式结果与开销	对照单 seed 证据
10	验证集检索诊断	判断内容价值与上限
11	下一阶段最短路线	下一批具体实验
12	独立贡献与消融矩阵	证明创新而非堆模块
13	强基线与数据扩展	有效后再扩规模
14	多 seed、漂移与复杂度	正式证据建设
15	GPU 队列与失败恢复	自动化执行规范
16	环境、代码与结果还原	交接和复现
17	里程碑与决策规则	阶段完成判据
18	来源与关键实验索引	定位原始证据

状态词的含义：“已完成”表示证据已落盘；“已实现待验证”表示代码存在但没有正式预测结果；“计划”表示后续条件性任务。训练成功只说明执行链路成功，不等同于科学假设成立。

本次只编制项目文档，不启动新实验。当前最新队列状态为 **COMPLETED**；新版本、更多 seed、外部基线和压力测试均按后续阶段执行。

02 研究问题与完整创新范围

核心问题

原 GTR 使用一个可学习全局表示 Q，按相位取片段，与局部输入经过二维卷积和残差融合。我们关注的不足是：不同预测样本需要的历史上下文不同；同一周期位置可能属于不同状态；过去有效的模式在漂移或突发变化时可能失效。

模块	要解决的问题	拟建立的贡献
A	应该看哪段历史？	多个历史跨度中的状态条件检索与动态选择
B	检索应使用多少？	根据输入与预测一致性，校准历史修正的可靠性
C	怎样学会正确检索？	同相位、相似未来状态的正例与困难负例监督

研究视角以检索为中心：不只是增加频率或尺度，而是让当前样本决定历史候选、候选权重和拒绝程度。A/B/C 均保留独立开关；暂时无效的模块保留代码、负结果和下一版方案。

原始设想与当前实现需要分开

初始 A 是多个独立周期 Q，分别负责短、中、长周期；B 是特征残差门控；C 是“同周期位置 + 类似状态”的对比学习。当前版本已经改为真实训练历史 continuation 的预测校正，具体差异见后续三页。

当前可支持： ETTh1 单 seed 中，真实历史检索带来小幅正向结果。

尚待支持： B/C 独立收益；新版 Solar 泛化；多 seed 稳定性；真正独立长周期建模；更强对照下的优势。

面向投稿的判断

目标是至少形成两个可解释、可独立验证的贡献，但创新点数量不保证任何 CCF 会议录用。投稿论证应建立在方法区别、同协议收益、统计稳定性、机制证据和资源代价上；本阶段以实验质量和最快有效迭代为优先。

03 官方复现与固定协议

原始仓库：GTR 官方代码。官方源文件、原始入口和配置保留；创新位于新增文件，关闭模块可恢复原 GTR。

主要设置	ETTh1	Solar
输入 T / 预测 H / seed	96 / 96 / 2024	96 / 96 / 2024
基础周期 / batch	24 / 256	144 / 64
配置学习率 / dropout	0.001 / 0.5	0.003 / 0
d_model / RevIN	512 / 开启	512 / 关闭
最大 epoch / patience	30 / 5	30 / 5
优化与损失	Adam、MSE、type3	Adam、MSE、type3
AMP / 梯度累积	关闭 / 不使用	关闭 / 不使用
train / val / test 窗口数	8449 / 2785 / 2785	36601 / 5161 / 10417

数据、评估和官方细节

- ETTh1 目标分段：[0,8640)、[8640,11520)、[11520,14400)；其余末尾数据不擅自加入。
- Solar 目标分段：[0,36792)、[36792,42048)、[42048,52560)。验证和测试输入携带前段 96 步上下文。
- StandardScaler 只在训练段拟合；MSE/MAE 在官方标准化空间计算，不混入逆变换指标。
- train/val 均 shuffle、drop_last；test 两项关闭。最佳 checkpoint 按官方验证早停选择。
- OneCycleLR 初始化把首轮学习率设为配置值 / 25；默认 type3 不 step 该对象。保持官方行为，不能只按配置字面值理解首轮 LR。
- 相位锚点实际是预测起点。新模块使用绝对起点，同时逐样本核对其基础周期余数与官方一致。

同预算指同最大训练预算、优化设置和早停规则；实际早停 epoch 可以不同，必须记录。当前任务是完整观测预测，没有缺失 mask 或 missing rate。

04 A：多周期历史记忆与检索

v4/v5 的实际检索对象

训练段形成不可变历史库，每条记录包含观察窗、输入键和已经发生的后续 H 步。对当前预测起点 t，仅允许历史起点 j 满足 `j + H <= t`，并匹配 `j mod P = t mod P`；P 是官方基础周期。验证、测试数据永不写入该库。

候选按相对历史年龄分成短、中、长三档，各最多 64 条，总候选不超过 192。每档均匀覆盖可用历史，再按每通道的状态距离检索。

> **当前三库是“同基础相位、不同历史周期年龄”的记忆。配置中的 [24,168,720] 或 [144,1008,4320] 保留来源和库数量，当前并未分别按三个周期取模。不能把这一步写成已经证明日、周、月独立周期建模。**

键、值与训练路径

- 15 维输入键：训练统计标准化的均值、log 标准差、趋势，加 12 个局部归一化形状分箱；局部 std 下限 0.1。
- 残差键编码器为 15→16→15，末层零初始化，使初始检索距离与验证诊断一致。
- 实际距离为平方欧氏距离；全局 top 3 后按逆距离和库 prior 加权。
- 历史未来先用候选观察窗归一化，再用当前观察窗的均值/尺度还原；只使用预测时可见输入。
- 路由为样本/通道条件化；C 直接训练同一检索键编码器。

当前限制与下一版

`global_topk` 先选候选再调库权重；若 top 3 全来自一个库，库 prior 在归一化中抵消，无法换入被排除的库。已实现的 `per_bank` 则每库各取 top 3，再连续混合；有正确性和梯度检查，尚无正式结果。

后续先单因素验证逐库路由。如果论文要主张独立多周期建模，还需实现真正不同周期的候选规则，并与当前历史年龄库比较。此为保留原创新范围的后续验证，不是现有事实。

05 B：可靠性门控与收益校准

当前预测融合

原 GTR 产生预测 y_base，历史库产生 y_hist；门控 g 为每样本/通道一个标量，在预测步之间共享。v5 的修正为：

```
s = 0.2 * tanh(a / 0.2)
```

```
y = y_base + s * g * (y_hist - y_base)
```

关闭 B 时 g=1；没有有效历史时直接输出 y_base。a 零初始化，初始预测和原模型随机流精确一致。s 允许有符号校正，不能无条件称为凸混合；其范围限制了修正幅度。

门控输入与训练监督

输入由当前观察窗统计、两路预测的 cosine 一致性、修正相对幅度和差异组成。描述符中的预测分支 detach，避免门控通过描述符改造专家。未来标签仅用于训练期最优混合系数：

```
delta = s * (y_hist - y_base)
```

```
g_star = clip(<Y-y_base, delta> / (||delta||^2 + eps), 0, 1)
```

g_star stop-gradient；校准损失按修正能量加权，系数 0.05。验证与测试仍使用纯 MSE，不使用门控 oracle。

需要证据支持的性质

g=0 回到当前共同训练的 GTR 分支，不能保证等于已经完成的 baseline checkpoint，也不能保证训练后“不伤 baseline”。已验证的是初始行为等价、推理不读未来和结构上的拒绝能力。

v5 加 B 后整体弱于 A5。下一步比较动态门控与固定门控，检查门控是否只是缩小有效修正；记录 oracle 标签分布、gate 饱和、校准误差和各库预测分歧。候选距离或库间分歧可作为后续可靠性输入，但一次只验证一个改动。

06 C：状态对比检索学习

正例与困难负例

使用训练目标的未来平均水平和趋势构造 regime；先减去观察窗水平，再除以观察窗尺度。候选必须同基础相位、因果可用，并与当前完整输入/目标窗口不重叠：`t-j >= T+H`。

在这些历史候选中，未来 regime 最近者作为正例，最远者作为困难负例；要求至少两个候选、正例足够相似、正负距离有区分。这样监督的不只是“同一时刻”，还包括“状态相似”。

当前损失与实现边界

```
L_train = L_forecast + 0.05 * L_gate + 0.002 * L_contrast
```

其中关闭的模块不保留对应 loss。对比温度为 0.1；v5 默认 cosine 正负 logits。query 未来只在训练 criterion 中读取；验证、测试和预测前向不接收 query 的未来。

历史候选及其已发生 continuation 来自固定训练段。与缓存过时 embedding 的队列不同，当前候选键在前向中使用同一编码器重新计算，因此恢复不需要动态跨 batch 缓存。

已解决的问题与未解决的问题

- 旧版 batch 内同相位候选在 Solar 的有效 anchor 仅约 3.55%；真实历史库使 ETTh1 ABC4/ABC5 的有效率约 93.66%。
- 有效 anchor 多只说明监督可用，不证明预测有效。C 在 AB5 背景下有小幅改善，但仍缺 AC5 对照。
- 实际检索是欧氏距离，v5 对比是 cosine，几何不一致。`contrast_metric='euclidean'` 已具备开关，未正式验证。

后续先补同版本 AC，再单独验证度量一致性。诊断主损失与辅助损失的编码器梯度大小和方向；不以对比 loss 下降代替检索质量或预测收益。

07 版本演进与负结果

以下为已完成正式测试结果，均 T96/H96、seed 2024。MSE/MAE 越小越好；保留全部方向，避免只展示最好一次。

数据	版本	MSE	MAE	判断
ETTh1	B1	0.367499	0.392714	MSE 降、MAE 微升；RNG 变化
ETTh1	A1	0.378976	0.399294	独立周期表无增益
ETTh1	AC1	0.380971	0.397571	联用仍退化
ETTh1	ABC1	0.380605	0.393895	联用仍退化
ETTh1	B2	0.369723	0.393385	保持 RNG 后不增
ETTh1	A2	0.383216	0.396112	中心化残差仍过拟合
ETTh1	AC2	0.383070	0.395522	联用仍退化
ETTh1	ABC2	0.383095	0.395404	联用仍退化
ETTh1	B3	0.370675	0.393581	预测一致性门控未增
ETTh1	A3	0.385247	0.397886	因子化降参数仍无效
ETTh1	AC3	0.385277	0.397996	联用仍退化
ETTh1	ABC3	0.385066	0.397727	联用仍退化
Solar	B3	0.178793	0.240219	MSE 降、MAE 升
Solar	A3	0.229461	0.297949	最佳 epoch 1，明显退化
Solar	ABC3	0.225285	0.295778	完整旧版明显退化

v2 保留基础 Q 并把长库中心化；v3 用水平/趋势/幅度系数，长记忆参数 6216→777。两者都未解决训练误差下降、验证误差上升的问题，因此 v4 改变检索对象，而不是继续调日历表规模。

B1 初始化消耗随机流，微小改善不能独立归因门控。之后 fork_rng 保持初始化随机流。Solar 旧版负结果不能直接推断新版真实历史库的泛化表现。

工程失败另存：同名 queue 遮蔽标准库、入口 super 递归已修复；4 个失败 smoke 与 4 个因依赖失败未启动的正式配置保留，后者不算训练失败。

08 最新正式结果与资源观察

ETTh1：同 seed、同预算、同评估资产

模型	MSE	MAE	MSE 降低	MAE 降低
GTR	0.369598	0.392604	—	—
A4	0.368977	0.392325	0.1681%	0.0713%
AB4	0.369042	0.392228	0.1507%	0.0959%
ABC4	0.368974	0.392199	0.1690%	0.1032%
A5	**0.366727**	**0.391116**	0.7770%	0.3792%
AB5	0.368004	0.391900	0.4313%	0.1794%
ABC5	0.367629	0.391734	0.5328%	0.2217%

v5 只把 `0.2*tanh(a)` 改为 `0.2*tanh(a/0.2)`；保持零初始输出与幅度范围，修正新增参数的有效更新尺度。实际强度由约 0.015–0.017 增至约 0.068–0.070，改善幅度增加。官方优化器、LR 和预算未变，但新增参数的优化动态确实变化，应明确归因。

模型	参数量	记录峰值 MiB	最佳 / 总 epoch
GTR	633,754	622.0	10 / 15
A5	634,314	794.0	9 / 14
AB5	634,507	814.0	10 / 15
ABC5	634,507	854.0	10 / 15

A 新增 560 个参数，ABC 新增 753 个，但历史数据 buffer 不计参数。记录推理总时间 GTR/A5/AB5/ABC5 分别为 0.02865 / 0.28756 / 0.45016 / 0.20751 秒，均 11 batches；设备/并发时段不同，不能作为严格速度排名。

数据	论文 MSE / MAE	本基线 MSE / MAE	绝对差 MSE / MAE
ETTh1	0.367 / 0.391	0.369598 / 0.392604	+0.002598 / +0.001604
Solar	0.176 / 0.235	0.181172 / 0.236659	+0.005172 / +0.001659

论文参考为 2025–2029 五 seed 均值；本基线为 seed 2024，优化代码行为保持官方，但 seed 统计口径不同，不能称完全同协议统计复现。

09 验证集诊断：检索为何值得继续

这一页是**验证集预测诊断**，不是正式测试成绩。诊断没有 optimizer step，不使用测试目标；候选仅来自训练段，满足因果边界。完整验证集评估不 shuffle/drop_last，因此也不同于官方早停批次平均。

ETTh1：全部 2785 个验证窗口

固定诊断设置	MSE	MAE
已训练 GTR	0.675533	0.540662
同相位历史检索单独预测	0.823224	0.616709
GTR + 0.1 固定检索混合	0.669114	0.538264
GTR + 0.2 固定检索混合	0.667404	0.538377

检索单独弱于模型，但小幅混合改善两项指标，支持把它作为校正。短/中/长候选的实际 top3 权重贡献约为 61.48% / 22.75% / 15.77%；跨库组合优于单库诊断。

Solar：全部 5161 个验证窗口

固定诊断设置	MSE	MAE
已训练 GTR	0.143148	0.214399
同相位全库混合，权重 0.1	0.143530	0.213799
同相位短库混合，权重 0.1	0.141646	0.212456
同相位长库混合，权重 0.1	0.145276	0.215345

Solar 的长库可能有害；全局最近邻仍给长库约 34.83% 权重。短库有内容价值，为逐库选择和可靠性拒绝提供了实际验证任务。

解析 oracle 使用真实未来，只是上限诊断：例如 ETTh1 每样本/通道 oracle MSE 约 0.594408。它不是可部署模型结果，不能放入正式方法排行榜，也不能用于测试集选型。

10 下一阶段最短执行路线

先补归因，再修机制

顺序	任务	完成判据
1	ETTh1 补 AC5；冻结 v5 其他设置	C 在不含 B 时的作用可比较
2	Solar 先 smoke + 新版 A5	新历史库是否避免旧 A3 退化
3	Solar 有信息价值后补 AB/AC/ABC	完成第二数据集同版模块归因
4	单改 global_topk→per_bank	路由能否拒绝有害年龄库
5	固定 A/B，仅改 C 为 Euclidean	对比监督与检索几何是否一致
6	根据误差诊断调整 B 的一项因素	门控收益可解释，而非整体降幅

每个新配置有独立 ID 和 smoke，基线回归检查通过后进入统一队列。已有 `per_bank` 与 Euclidean 开关不代表已有正式结果。round6 生成器草稿会组合部分改动，应按这里的单因素计划拆分、核对配置后再启动。

结果分支

- A 有效、B 变差：比较固定与动态 gate；检查校正强度、gate 分布、oracle 可识别性和不同库的预测分歧。
- C 候选充分但无收益：检查距离一致性、正例是否可预测、主/辅助梯度比例，再调整一个损失因素。
- Solar A 再次变差：回到短/中/长库的验证误差、实际选中比例与归一化迁移；保留全部库的研究范围。
- 两数据集都有值得继续的方向：冻结方法，再进入配对多 seed。
- 无法形成有效组合：继续修候选与机制，暂停扩数据、外部基线和论文包装。

不设“必须提升某固定百分比”的机械门槛。决策同时看 MSE/MAE、跨数据方向、模块归因、波动及成本；正式结论仍需要统计验证。

11 独立贡献与最小消融矩阵

配置	快速阶段状态	核心比较
GTR	两数据集已完成	所有改进的父模型对照
A5	ETTh1 已完成	A 与 GTR：检索内容是否有效
AB5	ETTh1 已完成	AB 与 A：B 的独立作用
AC5	待补	AC 与 A：C 的独立作用
ABC5	ETTh1 已完成	ABC 与 AB/AC：组合与交互

C 必须训练 A 的真实检索编码器；当前配置禁止无 A 的 C。因此不机械运行八种开关组合。B 的证据来自 AB−A 和 ABC−AC；C 的证据来自 AC−A 和 ABC−AB。

方法有效后再补的机制对照

模块	对照设计	必须控制的因素
A	单库 / 多库；固定 / 学习路由；global / per_bank	总候选数、训练预算和历史覆盖
B	固定 gate / 动态 gate；有 / 无校准监督	同一 A、相同修正参数化
C	无对比 / 普通负例 / 同相位困难负例	同一候选库、同一实际检索度量

如果要证明多库优势，不能让多库只因为看了更多候选获益。独立长周期候选库与年龄库的比较也要保持总候选预算。

同协议条件

固定 T/H、seed、batch、训练/验证/测试资产、最大 epoch、早停、优化器/LR、指标代码和 checkpoint 选择；新增模块及其 loss 权重显式记录。方法代码修改后重跑基线 smoke。

消融是检验完整研究范围，不是缩减创新方案。最终论文主张依据独立收益与机制证据形成，不能仅以“模块均存在”代替证明。

12 Baseline 与数据扩展计划

当前只做直接父模型与内部变体

GTR 是最关键对照；当前阶段不铺大量外部模型。方法冻结并出现值得统计验证的收益后，先补少量类别代表。

模型	比较意义	阶段
GTR	最直接父模型，预算与资产一致	当前及全部阶段
DLinear	轻量线性、趋势/季节分解代表	正式扩展
CycleNet	周期模板，与 A 最相关	正式扩展
PatchTST	Transformer 类强基线	正式扩展
iTransformer	强调跨变量作用时增加	可选，不预先全跑

优先使用官方实现；仓库内已有相关模型可以缩短接入，但应核对与官方版本的区别。外部方法不强行套用 GTR 的全部优化器超参数；采用官方推荐设置、固定数据与指标，并透明记录输入长度、训练预算与搜索成本。

数据与预测长度

- 快速阶段保持 ETTh1/Solar、T96/H96、seed 2024，不增加更多 seed 或全数据集。
- 方法冻结后先增加一个官方支持的长预测范围，再根据结果补齐所需范围，不能混合不同 horizon 的数字排名。
- 第三个数据集从尚未参与方法设计的公开数据中选择；可考虑官方仓库支持的 Weather 或 Electricity，选择前核对来源、周期差异和预处理。
- 若验证插入其他 backbone 的可迁移性，采用“同 backbone 原始版 / +TrustGTR”的配对比较，只在主方法成立后开展。

来源

DLinear 官方仓库；CycleNet 官方仓库；PatchTST 官方仓库。这是未来对照计划，不表示已经运行或验证优于这些方法。

13 多 seed、漂移与资源证据

方法冻结后进行配对统计

基线与最终方法使用同一组 seed；可采用原论文 2025–2029 五 seed，2024 保留为探索筛选。先跑 GTR、最终方法及必要归因版本，再补完整机制消融。报告均值、标准差、逐 seed 差异和跨数据一致性。

单 seed 不声称统计显著。若使用配对置信区间或 bootstrap，要明确分析单位；重叠预测窗口不是独立样本，不能直接按窗口数量夸大置信度。

当前多轮查看过同一 ETTh1 测试结果，应作为探索性证据。后续选型和权重只用 train/val；冻结后增加未参与设计的新数据或 holdout 场景。多 seed 检验训练随机性，不能消除测试选择偏差。

可靠性故事的直接检验

- 自然测试区间分层：平稳、输入水平变化、趋势变化；分层规则依据训练统计或预测时可见输入预先定义。
- 每层报告 MSE/MAE、gate 分布、各库权重和检索带来改善/伤害的比例；best-model 验证/测试诊断单独统计。
- 再做固定输入噪声、异常点、水平/趋势变化压力测试。正常测试与压力测试分开报告，不能改原测试资产后沿用原 ID。
- 未来目标只能在评估后用于分析 oracle 或真实收益；推理与分层决策不得使用它。

复杂度与性价比

统计参数、历史库 buffer/存储、单 epoch/总训练时间、推理延迟、峰值显存；能可靠取得时再报告 FLOPs/MACs。当前观测显示检索有额外推理代价，不能因参数少宣称低成本。

严格速度比较采用同设备、同 batch、同精度、预热和 CUDA 同步；区分模型前向、数据读取和完整流程。优化候选索引缓存或计算布局时保持数值协议，不静默缩候选、缩模型或缩训练。

14 GPU 队列与失败恢复

已实现的调度机制

统一调度器后台运行、非阻塞轮询，最多三个实验。依据 GPU UUID、实时空闲显存、历史峰值与少量安全余量补位；能跑一个就跑一个，资源增加后再补，不能以虚假 tensor 囤积显存。

启动临界区用共享 flock 保护 GPU 选择、显存预留、任务登记与 PID 写入。恢复时重新登记收养的活任务，避免崩溃窗口漏算资源。记录每任务配置、日志、PID、状态、退出码和峰值。

状态/错误	处理
SUCCESS	保存指标，归档并自动汇总，不重复启动
OOM	清理自身进程，更新估计与次数，指数退避回队列
WAITING_RESOURCE	保留队列、低频等待，不占 GPU
DATA / CONFIG / CODE_ERROR	定位修复；新 ID 与 smoke 后再启动，不无限重跑
NAN_OR_DIVERGENCE	保存最后状态，诊断数值问题
EXTERNAL_KILL	完整兼容 checkpoint 才可恢复
UNKNOWN_ERROR	保存错误，有限诊断后暂停该任务

OOM 重试要求比上次启动时更多空闲显存或更大 GPU，不用清理后显存误作参照；退避记录 next_eligible_time，较多失败转长期资源等待。只管理本用户确认归属的进程。

可用操作与当前状态

```
cd /mnt/data/zza/code/TrustGTR
bash scripts/queue.sh status configs/queue_historical_v5.json
tail -f runtime/queue.log
```

当前 v5 已 COMPLETED，队列累计 11 项成功，包含沿用 baseline/smoke；无待跑和运行任务。start/stop/resume 接口保留给后续队列。最新十项 CPU 假任务测试全部通过，未分配 GPU；不修改正式 batch/epoch 来适配资源。

15 环境、代码与结果还原

独立环境与版本

环境前缀 `.conda`：Python 3.10.13、torch 2.0.1+cu118、CUDA runtime 11.8、numpy 1.24.4、pandas 1.5.3、scikit-learn 1.3.2、PyYAML 6.0.2。依赖锁文件位于 configs。驱动显示 CUDA 12.2 不等于必须安装对应 Toolkit。

原始 commit 为 `d94161906151bdc0c94f4d21c2b0ca356aeb3135`。原始 tracked 源文件未修改；新增代码未自动 commit/push，每 run 保存额外代码快照及 hash。

位置	用途
models/GTR.py	保留的原模型
models/TrustGTR.py / HistoricalMemory.py	A/B/C 与静态历史库
exp/exp_repro.py	官方循环观察、原子保存与恢复
scripts/run_experiment.py	官方同协议入口
scripts/run_trust_experiment.py	创新入口、绝对相位、训练库绑定
scripts/experiment_queue.py / queue.sh	后台调度及 status/stop/resume
artifacts/evaluation/	固定 split、scaler 与校验资产
runs/ / reports/	唯一实验与自动结果表

每正式 run 保存 resolved_config.yaml、command.sh、env.txt、git_state.txt、code.diff、train.log、metrics.json、status.json、resource_usage.json、checkpoints、untracked_code 与 code_manifest。

last.pt 包括 model/optimizer/scheduler/早停/epoch/global step/最佳状态及随机状态，原子写入并检查。只从完整 epoch、相同科学指纹恢复；不兼容或损坏则新 ID 从头开始，预算不变。

历史数据 buffer 不进 state_dict；恢复先用同一训练资产重新绑定并核对 hash。ETTh1.csv / solar_AL.txt 复用已有公开数据副本，已核对 SHA256；未另行证明与上游逐字节一致，来源与 hash 保留在配置中。

GPU 曾核对逻辑 0=4090、逻辑 1=4080，启动仍使用 UUID。偏差简明记录位于 `/mnt/data/zza/code/badandgood/TrustGTR.md`。

16 里程碑、完成判据与交付

里程碑	当前状态	可审查完成判据
M1 快速复现	已完成	独立环境、两数据集、官方基线和固定资产可还原
M2 新版归因	部分完成	ETTh1/Solar 同版矩阵齐全，A/B/C 作用可区分
M3 方法冻结	待完成	验证集选型、配置与代码冻结，基线回归通过
M4 稳定性	待完成	配对多 seed、均值/波动、必要消融和全部原始结果
M5 强对照与机制	待完成	少量强基线、额外场景、漂移与资源代价
M6 论文论证	条件性开展	独立贡献与证据链足以支持研究主张

当前共有 **23 个成功正式实验**，其中两个 baseline；另有 **28 个成功 smoke**。保留 **2 个 CODE_ERROR 记录**，含未启动依赖任务。它们是执行记录，不是创新成功率或统计样本量。

决策与失败分支

单 seed 用于筛方向；两项指标与不同数据上的趋势、独立模块收益和成本共同决定是否扩大。未形成价值时返回候选质量、状态监督或校准机制，保留 A/B/C，不通过更多预算掩盖问题。

遇到数据、代码或配置错误先修根因；资源等待不是方法失败。若可靠性门控持续无增益，保留负结果并重新设计其监督和输入，不把它包装为已证实贡献。

执行与交付方式

代码、配置、诊断和授权实验由项目代理直接完成；用户只在涉及资源授权、目标改变或不可逆操作时介入。按工作批次推进，不承诺依赖共享 GPU 的固定完成日期。

每阶段交付：关键改动、配置差异、命令与退出状态、指标和成本、证据路径、继续/调整的判断及下一步。最终研究交付应包含可还原代码与环境、数据资产索引、全部结果表、完整消融和方法局限。

17 来源与关键实验索引

外部来源

- GTR 官方仓库与 README：原结构、安装和运行入口。
- GTR 论文：Enhancing Multivariate Time Series Forecasting with Global Temporal Retrieval。
- GTR OpenReview 页面：原论文信息；本文不据此预判本项目投稿结果。
- DLinear、CycleNet、PatchTST：未来外部基线的官方来源。

可定位的正式 run

以下 ID 均位于项目 `runs/` 下，读取 metrics.json；详细配置读取 resolved_config.yaml。

GTR ETTh1：`gtr__etth1__forecast__t96_h96__seed2024__20261004_214520`

GTR Solar：`gtr__solar__forecast__t96_h96__seed2024__20261004_214520`

A5：`trustgtr_a5__etth1__forecast__t96_h96__seed2024__20261005_110620`

AB5：`trustgtr_ab5__etth1__forecast__t96_h96__seed2024__20261005_110620`

ABC5：`trustgtr_abc5__etth1__forecast__t96_h96__seed2024__20261005_110620`

内部证据与文档维护

自动总表：`reports/latest_results.csv`、`.md`。诊断：`reports/retrieval_headroom_etth1_fullval_banks.json` 与 `retrieval_headroom_solar_fullval_banks.json`；这些是验证集诊断，oracle 不算正式模型结果。

固定评估资产目录：ETTh1 `bfe9623f632b1c68ce78`；Solar `8c343b57ef82b26b213a`，位于 artifacts/evaluation。全过程偏差索引：code/badandgood/TrustGTR.md。

本 PDF 数值由 metrics 自动代入；同名 evidence.json 保存来源 hash 与队列快照，可编辑 Markdown/DOCX 同时交付。更新文档时重新核对截止状态，保留旧版本，不把计划改写为已执行事实。